

Elaborazione di Immagini Mediche
Corso di Laurea Magistrale in Ingegneria
Biomedica



**Politecnico
di Torino**

PolypGen Challenge

2024-2025

Leo Rebecca – 319805

Liendo Maria Sol – 336970

Scarcelli Erica – 324125


Venerito Silvia – 319638

1.Introduzione

Il carcinoma colon rettale è una delle principali cause di morte per tumore, con un tasso di mortalità vicino al 50%, la cui principale causa è la lenta trasformazione di polipi adenomatosi o serrati. La colonscopia è considerata il gold standard per la diagnosi, rimozione e capacità di rilevare i polipi. Delimitarne i confini è cruciale, in quanto la rimozione incompleta può ridurre l'efficacia della prevenzione e lasciare la possibilità dell'evoluzione verso il carcinoma.

Negli ultimi anni sono stati sviluppati diversi metodi basati sull'intelligenza artificiale per aiutare i gastroenterologi nel riconoscimento e nella segmentazione di polipi, in modo da ridurre la variabilità inter-operatore. La mancanza di dataset ampi ed eterogenei ha però limitato la validazione e la generalizzazione di questi metodi.

L'obiettivo di questo progetto è lo sviluppo di un sistema per la segmentazione automatica dei polipi presenti sulla parete del colon in immagini di colonscopia. Il sistema è basato su un'architettura U-net ed è stato generato includendo dati messi a disposizione da sei centri diversi con più di 300 pazienti. Nei paragrafi successivi vengono descritte le scelte metodologiche che hanno guidato la definizione della pipeline di elaborazione, comprendenti la divisione del dataset e la preparazione dei dati, l'addestramento del modello, il post processing dei risultati e la valutazione tramite metriche di accuratezza.



2. Materiali e metodi

2.1 Dataset

I dati utilizzati in questo progetto provengono dal dataset PolypGen [1], una raccolta open-access di immagini e sequenze video di colonscopia acquisite da sei centri diversi (Egitto, Francia, Italia, Norvegia e Regno Unito). Il dataset comprende:

- 1.537 frame singoli (tutti contenenti polipi), suddivisi per centro di provenienza.
- 2.225 frame estratti da 23 sequenze video, inclusi sia frame positivi (con polipi) che negativi (senza polipi).

Ogni immagine è accompagnata da annotazioni a livello di pixel (pixel-level ground truth), realizzate da sei gastroenterologi esperti, che delineano con precisione le aree dei polipi. Queste maschere di

segmentazione sono essenziali per lo sviluppo e la validazione di sistemi CAD (Computer-Aided Detection) e modelli di deep learning.

2.1.1 Diversità e challengers del dataset

Il dataset riflette un'ampia variabilità in termini di: popolazione paziente (differenze demografiche e cliniche), attrezzature endoscopiche (dispositivi e protocolli di acquisizione diversi tra i centri) e procedure di resezione dei polipi (tecniche variabili tra i professionisti).

Questa eterogeneità permette di valutare la generalizzazione dei modelli e l'addestramento su dati multi-centro migliora la robustezza, ma può aumentare il rischio di falsi positivi [1].

Per garantire un'analisi completa della generalizzazione del modello, sono state proposte diverse configurazioni di set di dati per l'addestramento e la convalida, queste sono state valutate tramite metriche di valutazione per rivelare la robustezza dei metodi di deep learning.

Dataset Iniziale - Centri			
	#immagini	#negativi	%negativi
C1	256	5	2%
C2	301	32	11%
C3	457	1	0%
C4	227	81	36%
C5	208	2	1%
C6	88	5	6%

In Tabella 1 e Tabella 2, viene fornita una descrizione completa della raccolta dei set di dati, ovvero per ogni centro e ogni sequenza viene indicato: il numero di immagini, il numero di immagini senza presenza di polipo (negativa) e la rispettiva percentuale di immagini negative sul totale.

Tabella 1 . Numero di immagini e numero di negativi appartenenti ai 6 centri del dataset iniziale.

Dataset Iniziale - Sequenze							
	#immagini	#negativi	%negativi		#immagini	#negativi	%negativi
Seq1	36	36	100%	Seq13	250	51	20%
Seq2	63	3	5%	Seq14	249	49	20%
Seq3	15	0	0%	Seq15	116	0	0%
Seq4	48	2	4%	Seq16	40	7	18%
Seq5	250	51	20%	Seq17	63	19	30%
Seq6	41	29	71%	Seq18	63	7	11%
Seq7	48	48	100%	Seq19	56	1	2%
Seq8	73	19	26%	Seq20	52	21	40%
Seq9	51	9	18%	Seq21	56	31	55%
Seq10	25	18	72%	Seq22	46	2	4%
Seq11	228	92	40%	Seq23	56	20	36%
Seq12	250	0	0%				

Tabella 2. Numero di immagini e numero di negativi appartenenti alle 23 sequenze del dataset iniziale.




Figura 2: Immagini del Dataset

2.1.2 Divisione del Dataset in Construction set e Test set

Confronto dei due approcci per la suddivisione del dataset:

Divisione per Centro. Il training set comprende i dati provenienti da 5 dei 6 centri disponibili, mentre il sesto centro è stato riservato esclusivamente per la validazione. Il test set è costituito da sequenze video complete, preservando così l'integrità temporale dei casi clinici e simulando uno scenario reale di applicazione.

Divisione Randomizzata. In questo approccio, sia il training set (80% dei dati) che il validation set (20% dei dati) includono immagini provenienti da tutti e 6 i centri, distribuite in modo casuale e in entrambi i set vengono aggiunte delle sequenze come descritto in Tabella 3. Anche in questo caso, il test set è mantenuto rigorosamente separato, composto da sequenze complete non presenti negli altri set.

Criteri di Selezione

A partire dalle immagini nel dataset open access fornitoci, per aumentare la robustezza del modello, sono state selezionate alcune sequenze e ne sono state rimosse altre. Sono state incluse deliberatamente immagini tecnicamente critiche: sfocate, con bassa illuminazione o artefatti. Sono state considerate tutte le varianti morfologiche dei polipi e si è cercato di mantenere un bilanciamento tra casi positivi e casi negativi.

Risultati Comparativi

		Divisione per centri				Divisione Randomizzata		
		#immagini	#negativi	%negativi		#immagini	#negativi	%negativi
Training set	C2, C3, C4, C5, C6	1281	121	9.45%	80% immagini di centri + sequenze: 1, 5, 6, 9, 12, 13, 21	2213	314	14.19%
Validation set	C1	256	5	1.95%	20% immagini dei centri + sequenze: 3, 19, 20	479	43	8.98%
Test set	Tutte le sequenze				Sequenze: 2,15,16			

Tabella 3. Divisione dataset iniziale in training, validation e test set. In celeste divisione per centri, in verde divisione randomizzata.

2.2 Metriche

Le metriche di prestazione utilizzate sono state: IoU, Dice, Precision, Recall e Accuracy. Le prime due, IoU e Dice, sono le più indicative per la valutazione dell'efficienza dei modelli nella localizzazione degli oggetti. In particolare, il Dice viene spesso usato in ambito medico perché è molto sensibile al mismatch tra le due aree, pertanto è stata scelta come metrica decisionale.

Le metriche sono descritte in termini di TP (true positives), FP (false positives), TN (true negatives, FN (false negatives).

IoU- Intersection over Union

Descrive il rapporto tra l'intersezione della ground truth e le regioni predette e l'unione di entrambe. Misura il rapporto di sovrapposizione tra le due regioni.

$$IoU = \frac{TP}{TP + FP + FN}$$

Dice Similarity Coefficient

Descrive l'overlap tra la segmentazione predetta e la ground truth. È un valore compreso tra 0 e 1, dove 0 rappresenta sovrapposizione nulla e 1 coincidenza perfetta.

$$Dice = \frac{2 \cdot TP}{2 \cdot TP + FP + FN}$$

Acc- Accuracy

È la metrica più semplice e misura la proporzione di pixel classificati correttamente sul totale.

$$Acc = \frac{TP + TN}{TP + TN + FP + FN}$$

Prec- Precision

Descrive l'affidabilità della predizione dei pixel positivi. Un valore di Precision alto significa pochi falsi positivi.

$$precision = \frac{TP}{TP + FP}$$

Rec- Recall

Misura la capacità del modello di individuare i pixel realmente positivi. Un valore di Recall alto significa pochi falsi negativi.

$$Recall = \frac{TP}{TP + FN}$$

RAE-Relative Absolut Error

Descrive la valutazione dell'errore relativo tra l'area predetta (A_{pred}) e l'area reale (A_{GT}), identificata come ground truth. È un valore sempre ≥ 0 , $RAE=0$ indica che l'area predetta coincide con quella reale, di conseguenza più il valore RAE è alto più la discrepanza tra le due aree è maggiore.

$$RAE = \frac{|A_{pred} - A_{GT}|}{A_{GT}}$$

2.3 Preprocessing

Sono state proposte e valutate diverse strategie di preprocessing, tutte con l'obiettivo di rendere le immagini dell'intero dataset più omogenee in termini di dimensioni, distribuzione cromatica e qualità visiva, riducendo rumore e distorsioni affinché l'allenamento della rete risulti più robusto. Le varie prove prevedono: resize, omogenizzazione del colore, rimozione artefatti della luce e filtraggio.

2.3.1 Resize e binarizzazione delle maschere

A causa della grande eterogeneità nelle dimensioni delle immagini da 384×288 pixels fino a 1920×1080 pixels, attraverso la libreria *skimage transform*, è stato applicato il resize a tutte le immagini per uniformare le dimensioni a 256×256 pixels. Le maschere originali hanno valori codificati in 8 bit (0/255) e, poiché il modello richiede in ingresso maschere con valori 0/1, esse sono state binarizzate mettendo una soglia a 127, che rende tutti i valori minori della soglia pari a 0 e maggiori pari a 1.

2.3.2 Omogeneizzazione: Normalizzazione del Colore di Reinhard

Avendo immagini provenienti da pazienti, centri e strumenti diversi, per omogeneizzare il colore e la luminosità delle immagini, è stata applicata la tecnica di normalizzazione di Reinhard [2]. Questo metodo mira a ridurre la variabilità cromatica e di intensità tra le immagini, mappando le statistiche di colore (media e deviazione standard) delle immagini sorgente rispetto a quelle di un set di immagini di riferimento. Come target di riferimento sono state prese 30 immagini random dal centro C1.

Il processo si articola in:

- **Conversione RGB-Lab:** Le immagini vengono trasformate nello spazio colore Lab (Luminosità, canali 'a' e 'b'), dove L rappresenta l'intensità e 'a'/'b' i colori.
- **Mappatura Statistica:** Per ogni canale (L, a, b), la media e la deviazione standard dell'immagine sorgente vengono adattate a quelle del target, utilizzando la formula:

$$I_{Lab}^{norm}(x, y, c) = \frac{I_{Lab}(x, y, c) - \mu_c^{source}}{\sigma_c^{source}} \times \sigma_c^{tgt} + \mu_c^{tgt}$$

dove:

- $I_{Lab}(x, y, c)$ è il valore del canale $c \in \{L, a, b\}$ del pixel in posizione (x,y) dell'immagine sorgente,
- $\mu_c^{source}, \sigma_c^{source}$ sono media e deviazione standard del canale c dell'immagine sorgente,
- $\mu_c^{tgt}, \sigma_c^{tgt}$ sono media e deviazione standard del canale c del set di immagini target
- $I_{Lab}^{norm}(x, y, c)$ è il valore normalizzato.
- **Clamping e Conversione Lab-RGB:** i valori ottenuti vengono limitati agli intervalli validi dello spazio Lab e riconvertiti in RGB.




Figura 3: La prima riga presenta le immagini originali. La seconda riga mostra le corrispondenti immagini a cui è stata applicata l'omogeneizzazione del colore.

2.3.3 Sph-Rimozione di artefatti luminosi

Per evitare che le maschere generate dal modello si concentrassero erroneamente sugli artefatti luminosi, è stata ideata una strategia per eliminarli e prevenire risultati indesiderati. Questa è strutturata in tre step:

1. Creare una maschera binaria dei riflessi speculari: si converte l'immagine in HSV e vengono impostate delle soglie fisse con l'obiettivo di identificare i riflessi. I pixel con valore di intensità (V) > 100 sono considerati molto luminosi e saturazione (S) < 40, poco saturi o quasi bianchi. A partire da queste condizioni si genera una maschera binaria.
2. Pulire la maschera dei riflessi con operazioni morfologiche: vengono rimossi pixel isolati e rumorosi, vengono chiusi i buchi piccoli, e le regioni individuate vengono espanse tramite operazioni di apertura, chiusura e dilatazione morfologica.

3. Eseguire l'inpainting: per eseguire questa operazione sono stati valutati due metodi diversi. Nel primo metodo si selezionano i pixel della maschera espansa che contengono il valore da sostituire nel difetto, escludendo quelli appartenenti alla maschera iniziale e quelli che cadono fuori dal range desiderato: non vengono mediati valori vicini a 0 o 255. Si calcola il colore medio dei pixel validi e si sostituisce il valore in ciascuna delle regioni identificate. Nel metodo 2, viene utilizzata una funzione apposita di `cv2.inpaint` che reintegra automaticamente le regioni con i valori dei pixel circostanti. Tra questi due metodi si è deciso di implementare solo il secondo in seguito ad un'analisi visiva.




Figura 4: La prima riga presenta le immagini originali. La seconda riga mostra le corrispondenti immagini a cui è stata applicata la rimozione degli artefatti luminosi

Tuttavia, come è visibile nella Figura 4, questa pipeline presenta alcune limitazioni, tra cui il riconoscimento meno accurato di riflessi luminosi di piccole dimensioni e la scarsa compensazione dei riflessi nelle immagini sfocate.

2.3.4 Filtraggio

Per migliorare le qualità delle immagini ai fini della segmentazione sono state valutate diverse combinazioni di filtraggio in base alle metriche ottenute allenando la rete U-Net, utilizzando la divisione del dataset per centri descritta precedentemente e applicando l'inferenza sulla sequenza 5. Le diverse tipologie di filtraggio prevedevano combinazioni tra filtro mediano con kernel 3x3, filtro ibrido bilaterale mediano e gamma correction 1.1, come descritto in Tabella 4 nella sezione Risultati.

In alcune prove è stata applicata l'equalizzazione CLAHE (Contrast Limited Adaptive Histogram Equalization) sul canale V (Value) in spazio HSV (Hue Saturation Brightness) per migliorare il contrasto locale e la visibilità dei dettagli. Questo tipo di equalizzazione è particolarmente adatto alle immagini di colonscopia [3] perchè consente di ridurre gli effetti dovuti a illuminazione non uniforme e di evidenziare meglio le strutture rilevanti, facilitando la segmentazione dei polipi.

Queste tipologie di filtraggio sono state confrontate con un'altra combinazione trovata in letteratura [3] denominata Filtro A, che prevede l'utilizzo di un filtro ibrido tra bilaterale con diametro pari a 5, e gaussiano con kernel 5x5, con aggiunta di equalizzazione CLAHE sul canale V e con limite 2.0.

2.4 Rete Neurale

È stata utilizzata una rete neurale `unet-s5-d16_fcn` configurata tramite il framework `MMSegmentation` sia pre-allenata con `cityscapes` (da qui a seguire verranno chiamati "pesi preallenati"), sia con pesi random non preallenati (da qui a seguire verranno chiamati "pesi random").

Nell'addestramento della rete sono state fatte le seguenti scelte sui parametri per ottimizzare le prestazioni.

- Batch Size: 4 per il training set e il validation set, 1 per il test set.

- Schema di addestramento: il training è stato impostato a iterazione con salvataggio dei checkpoint ogni 4000 iterazioni. È stato configurato il mantenimento di un solo modello, corrispondente a quello con il miglior punteggio in termini di mDice sul validation set.
- Dimensione delle immagini di input: 256x256.
- Loss Function: la testa principale di decodifica è supervisionata da una combinazione di Cross Entropy (con pesi 0.9 e 0.1) e Dice Loss (peso 1.0), mentre la testa ausiliaria utilizza una Dice Loss con peso 1.0.
- Ottimizzatori: parametri di default del config di riferimento U-Net di MMSegmentation (basati su AdamW) con un learning rate dell'ordine di 10^{-5} – 10^{-4} e weight decay pari a 0.01.
- Data Augmentation: sono stati utilizzati un flip orizzontale casuale con probabilità 0.5 e una PhotoMetricDistortion per rendere il modello più robusto alle variazioni di luminosità e colore provenienti dai diversi centri.

L'architettura finale è U-Net a due classi con normalizzazione BatchNorm su backbone e teste, una di decodifica e una ausiliaria, entrambe supervisionate tramite Dice Loss.

La scelta iniziale di Batch Size pari a 4 è stata dettata da vincoli di hardware, ma a causa di problemi riscontrati nell'utilizzo di Colab non sono state effettuate prove di addestramento della rete con Batch Size diversi, esempio 6 e 8. Inoltre, per lo stesso motivo, non è stato possibile personalizzare i parametri dell'ottimizzatore come il learning rate e il weight decay.

2.5 Postprocessing,

Per migliorare ulteriormente la segmentazione sono stati utilizzati i modelli deformabili come tecniche di postprocessing.

2.5.1 Snakes

Sulle maschere in uscita alla rete sono stati applicati snakes.

Lo snake attivo può essere utile per delineare polipi visibili nelle immagini la cui visibilità risulta ridotta [4] o eterogenea a causa delle differenze nei metodi di acquisizione adottati nei diversi centri.

$$E_{snakes} = \int_0^1 [\alpha \|v'(s)\|^2 + \beta \|v''(s)\|^2 + E_{ext}(v(s))] ds$$

$$v_{t+1} = v_t + \Delta t [\alpha L_1(v_t) + \beta L_2(v_t) + F_{ext}(v_t)]$$

- $\alpha = 2$;
- $\beta = 10$;
- per ottenere F_{ext} campo dei gradienti normalizzato all'immagine è stato applicato un filtro gaussiano con $\sigma = 3.5$;
- **numero iterazioni $t=70$** ;
- **numero di punti = 250**;
- **smooth every**: Il contorno viene regolarizzato periodicamente ogni iterazione;
- **step clip**: il massimo spostamento di ogni punto ad ogni iterazione è limitato ad 1.

I parametri sopra elencati sono stati scelti inizializzando lo snake sulle maschere della sequenza 2. Sono state effettuate varie prove valutando il cambiamento nelle performance del modello tramite l'utilizzo delle metriche Dice e RAE sia singolarmente su alcune maschere prese come esempio, che globalmente sull'intera sequenza calcolando i valori medi che esse assumevano prima e dopo l'applicazione dello snake.

Le performance ottenute applicando il modello su tutte le sequenze del test sono riportate nella sezione Risultati in Tabella 9,10,11.




Figura 5: La prima è maschera applicando il solo preprocessing, la seconda è la maschera con l'applicazione degli snakes, la terza è la ground truth.

3. Risultati e discussioni

3.1 Preprocessing

Si analizzano ora i vari risultati ottenuti che hanno portato alla versione finale del preprocessing. Tutte le scelte sono state effettuate valutando il Dice in tutte le prove, ritenuta la metrica più adatta per lo scopo del progetto.

Filtri	IoU (%)	Dice (%)	Prec (%)	Rec (%)	Acc (%)
Clahe+mediano(3.3) + gc1.1	17.73±30.06	21.32±34.67	32.09±45.11	18.48±31.32	96.08±4.87
Clahe + mediano (3.3) (FILTRO B)	19.45±32.18	22.81±36.40	32.04±44.78	20.44±33.75	96.81±4.14
Mediano + clahe (3.3)	14.64±28.22	17.51±32.78	27.78±43.46	15.29±29.34	96.45 ± 4.70
Ibrido:(bilaterale+mediano)+ clahe	13.37± 24.21	17.30 ± 29.66	26.43± 39.55	15.70 ± 28.40	94.01 ± 5.55
Clahe + Ibrido: (Bilaterale+Mediano)	17.42 ± 31.02	20.58 ± 34.63	31.83 ± 45.11	18.13± 32.20	96.74±4.30
Filtro A + Ibrido: (Bilaterale+Mediano) + clahe	15.10±28.74	18.14±32.61	29.66±44.08	16.17±30.99	96.32±5.07

Tabella 4. Metriche ottenute dall'inferenza usando le diverse combinazioni di filtraggio sulla sequenza 5.

Tra le varie combinazioni, il filtraggio con mDice migliore risulta quello che prevede un'equalizzazione dell'immagine (CLAHE) e in cascata un filtro mediano con kernel 3x3, denominato "Filtro B".

Sono state valutate le seguenti condizioni sulla sequenza 2:

- Confronto tra i dataset

Divisione del Dataset	IoU (%)	Dice (%)	Prec (%)	Rec (%)	Acc (%)
Divisione per Centri	46.53 ± 20.52	60.40 ± 22.67	48.61 ± 21.76	85.48 ± 28.74	94.87 ± 2.83
Divisione Randomizzata	67.12 ± 23.03	77.08 ± 24.06	73.37 ± 24.90	84.09 ± 27.48	98.21 ± 1.18

Tabella 5. Metriche ottenute dall'inferenza dalle due tipologie di divisione del dataset sulla sequenza 2.

La comparazione preliminare delle prestazioni del modello sulle due configurazioni, riportate in Tabella 5, ha evidenziato che la divisione randomizzata riporta risultati più consistenti in termini di metriche rilevanti (mIoU, mDice) suggerendo una migliore capacità di generalizzazione complessiva. Il sistema mostra migliori capacità di adattamento alla variazione della qualità dell'immagine e minor riconoscimento di falsi negativi anche in condizioni critiche.

Basandosi su questa analisi comparativa, si è deciso di procedere con il dataset suddiviso in maniera randomizzata per le fasi successive di addestramento e valutazione del modello.

- Confronto tra l'addestramento con i pesi random e con i pesi preallenati:

	IoU (%)	Dice (%)	Prec(%)	Rec(%)	Acc(%)
pesi random	67.12±23.03	77.08±24.06	73.37±24.90	84.09±27.48	98.21±1.18
Pesi preallenati	60.97±23.19	72.37±23.98	63.06±24.99	88.98±26.51	97.27±1.69

Tabella 6. Metriche ottenute dall'inferenza allenando la rete con pesi random e con pesi preallenati sulla sequenza 2. Il dataset utilizzato è quello con divisione randomizzata.

In seguito ai risultati riportati in Tabella 6 l'addestramento migliore è risultato quello con pesi random, di conseguenza, le valutazioni sul preprocessing sono state fatte utilizzando la combinazione di dataset con divisione randomizzata e con pesi random.

- Confronto Filtro A e Filtro B

Dataset Random pesi random	IoU(%)	Dice (%)	Prec(%)	Rec(%)	Acc(%)
Filtro A	66.33±26.37	75.43±27.71	76.80±25.48	77.47±31.51	98.07±1.98
Filtro B	40.33±33.37	48.75±37.10	52.99±39.32	51.97±40.37	95.36±5.67

Tabella 7. Metriche ottenute dall'inferenza applicando alle immagini il filtro A e il filtro B separatamente sulla sequenza 2. Il dataset utilizzato è quello con divisione randomizzata e allenando la rete con pesi random.

Come evidente in Tabella 7 l'addestramento con il filtro A risulta quello con le prestazioni migliori.

- Confronto tra le operazioni di preprocessing sulle immagini e le combinazioni tra di loro:

Dataset Random pesi random	IoU(%)	Dice (%)	Prec(%)	Rec(%)	Acc(%)
Solo omogeneizzazione	64.00±25.24	74.05±26.46	74.82±26.19	77.54±31.29	97.88±1.72
Omogeneizzazione + filtro A	63.03±23.84	73.85±24.30	71.30±27.03	82.69±28.72	97.57±1.91
Solo sph	66.97±24.24	76.71±24.69	74.13±25.67	83.66±28.68	98.12±1.55
Sph+filtro A	55.57±22.20	68.22±23.15	58.39±24.17	88.12±27.68	96.47±2.23
Sph+omogeneizzazione	61.29±22.40	72.81±23.50	65.15±24.14	86.53±27.74	97.41±1.74
Sph + omogeneizzazione + filtro A	62.00±28.30	71.61±28.71	83.39±26.44	69.60±32.90	98.15±1.63

Tabella 8. Metriche ottenute dall'inferenza applicando le diverse operazioni di preprocessing, quali omogeneizzazione, sph, filtro A e le combinazioni tra queste. Il dataset utilizzato è quello con divisione randomizzata e allenando la rete con pesi random.

Dai risultati ottenuti dai vari addestramenti sulla sequenza 2, descritti nelle precedenti tabelle, la combinazione finale migliore prevede: dataset randomizzato, pesi random e preprocessing che comprende solo la rimozione degli artefatti luminosi (sph).

3.2 Postprocessing

Si valutano ora i risultati ottenuti dal postprocessing su tutte le sequenze del test set, ovvero sequenza 2, sequenza 15 e sequenza 16. Per coerenza con le scelte effettuate nella fase di preprocessing, anche quelle sul postprocessing saranno valutate sui risultati ottenuti dalla sequenza 2.

Postprocessing Seq 2	Dice (%)	RAE(%)
Solo preprocessing	76.71±24.69	31.77±27.95
Snakes	77.17±25.12	26.20±26.40
Δ	+0.46±2.56	-5,57±8.75.

Postprocessing Seq 15	Dice (%)	RAE(%)
Solo preprocessing	78.72±25.64	26.03±22.98
Snakes	80.55±26.03	20.59±23.71
Δ	+1.83±1.90	-5.44±4.08.

Tabella 9 e 10. Metriche ottenute dall'inferenza applicando solo il preprocessing e preprocessing seguito da snakes sulla sequenza 2 a sinistra e sequenza 15 a destra. Il dataset utilizzato è quello con divisione randomizzata e allenando la rete con pesi random e il preprocessing prevede sph.

Postprocessing Seq 16	Dice (%)	RAE(%)
Solo preprocessing	47.67±35.71	45.90±33.78
Snakes	43.89±33.58	50.70±32.83
Δ	-3.78±3.43	+4.80±4.59.

Tabella 11. Metriche ottenute dall'inferenza applicando solo il preprocessing e preprocessing seguito da snakes sulla sequenza 16. Il dataset utilizzato è quello con divisione randomizzata e allenando la rete con pesi random e il preprocessing prevede sph.

Le tabelle 9, 10 e 11 riportano il confronto delle metriche calcolate sulle maschere prima e dopo l'applicazione del post processing. L'utilizzo degli snakes sulle sequenze 2 e 15 ha portato ad un miglioramento nella segmentazione dei polipi, come indicato dal Δ Dice positivo e dal Δ RAE negativo. Contrariamente, l'utilizzo di questo modello sulla sequenza 16 porta ad un peggioramento della segmentazione.

4. Limitazioni e sviluppi

Il training set utilizzato per allenare la rete è stato costruito scegliendo le sequenze visivamente migliori in modo da allenare la rete con immagini in cui il polipo era ben visibile. Un dataset più ampio avrebbe permesso di aggiungere altre sequenze con qualità più scarsa, il che avrebbe potuto portare ad una maggiore capacità di riconoscere i polipi in situazioni più critiche. Inoltre, per essere sicuri di aver ottenuto la performance migliore di filtraggio in uscita dalla rete, si sarebbero potute provare tutte le combinazioni dei filtri descritti in Tabella 4 sulla sequenza 2, con il dataset con divisione randomizzata e con pesi random, come fatto per il filtro A e il filtro B. Questo non è stato possibile a causa dei problemi riscontrati nell'utilizzo di Colab, che non hanno permesso di effettuare ulteriori prove di addestramento e inferenza della rete.

Un possibile approccio futuro potrebbe essere valutare le performance che si otterrebbero se si addestrasse una rete DeepLabV3+ con ResNet101 utilizzando il preprocessing e post processing validato dalle nostre prove. Questo confronto potrebbe essere utile in quanto la suddetta rete risulta quella con le prestazioni migliori [1].

Come spiegato nella paragrafo 2.5.1, i parametri relativi al post processing sono stati valutati e quindi scelti sulla base delle performance ottenute dall'applicazione del modello solo sulla sequenza 2. L'applicazione dello snake così inizializzato su altre sequenze non può garantire un miglioramento nelle prestazioni in quanto esso, per definizione, dipende fortemente dall'inizializzazione sull'oggetto in esame. Nelle tabelle 10 e 11 si può infatti vedere come il modello lavori diversamente su altre sequenze. Un ulteriore sviluppo futuro consiste nell'estendere l'approccio dalla segmentazione bidimensionale alla segmentazione tridimensionale, sfruttando sequenze video consecutive per ricostruire un volume coerente. Questo consentirebbe di ottenere informazioni spaziali più ricche e di migliorare la continuità della segmentazione tra frame adiacenti.

5. Bibliografia

1. Meziou, L., Histace, A., Precioso, F., Romain, O., Dray, X., Granado, B., & Matuszewski, B. J. (2014). Computer-assisted segmentation of videocapsule images using alpha-divergence-based active contour in the framework of intestinal pathologies detection. *International Journal of Biomedical Imaging*, 2014, 428583. <https://doi.org/10.1155/2014/428583>
2. Ramalingam, K., & Jamal, N. (2024). Enhancing colonoscopy image quality through multi-step computational pre-processing techniques. *Informatica*, 48(23), 47–60. <https://doi.org/10.31449/inf.v48i23.6498>
3. Roy, S., Panda, S., & Jangid, M. (2021, August). Modified Reinhard algorithm for color normalization of colorectal cancer histopathology images. In *2021 29th European Signal Processing Conference (EUSIPCO)* (pp. 1231–1235). IEEE. <https://doi.org/10.23919/EUSIPCO54536.2021.9616117>
4. Banerjee, S., Anghel, A., Fidon, L., Granado, B., Histace, A., Jha, D., ... Pogorelov, K. (2023). PolypGen: A multi-center polyp detection and segmentation dataset for generalisability assessment. *Scientific Data*, 10(1), 74. <https://doi.org/10.1038/s41597-023-01981-y>